

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi telah menghasilkan volume data yang sangat besar, terutama dalam bentuk teks. Data teks tersebut dapat berasal dari berbagai sumber seperti berita, media sosial, dokumen digital, dan komunikasi online. Namun, data dalam bentuk teks tidak terstruktur sehingga memerlukan metode khusus untuk dapat dianalisis dan dimanfaatkan secara optimal.

Natural Language Processing (NLP) merupakan salah satu cabang dari Artificial Intelligence yang berfokus pada kemampuan komputer dalam memahami, mengolah, dan menganalisis bahasa manusia. NLP memungkinkan sistem untuk melakukan berbagai tugas, seperti klasifikasi teks, analisis sentimen, serta pengukuran kemiripan antar dokumen.

Salah satu pendekatan yang umum digunakan dalam NLP adalah teknik feature extraction, yaitu proses mengubah teks menjadi representasi numerik agar dapat diproses oleh komputer. Metode yang sering digunakan dalam proses ini adalah Term Frequency-Inverse Document Frequency (TF-IDF), yang mampu merepresentasikan tingkat kepentingan suatu kata dalam dokumen.

Selain itu, untuk mengukur tingkat kemiripan antar teks, digunakan metode cosine similarity. Metode ini bekerja dengan membandingkan vektor representasi dari dua teks dan menghasilkan nilai yang menunjukkan tingkat kedekatan antar teks tersebut.

Berdasarkan hal tersebut, penelitian ini dilakukan untuk mengimplementasikan metode TF-IDF dan cosine similarity dalam menganalisis kemiripan antar teks. Penelitian ini diharapkan dapat memberikan pemahaman mengenai bagaimana teks dapat diolah menjadi informasi yang bermakna melalui pendekatan NLP.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, maka permasalahan dalam penelitian ini dapat dirumuskan sebagai berikut:

1. Bagaimana melakukan preprocessing teks untuk keperluan analisis NLP?

2. Bagaimana menerapkan metode TF-IDF dalam merepresentasikan teks?
3. Bagaimana mengukur kemiripan antar teks menggunakan cosine similarity?

1.3 Tujuan Penelitian

Tujuan dari penelitian ini adalah:

1. Mengimplementasikan proses preprocessing teks.
2. Menerapkan metode TF-IDF untuk representasi teks.
3. Menghitung tingkat kemiripan antar teks menggunakan cosine similarity.

1.4 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

1. Memberikan pemahaman mengenai penerapan NLP dalam analisis teks.
2. Menjadi referensi dalam pengembangan sistem berbasis teks.
3. Membantu dalam memahami konsep feature extraction dan similarity dalam NLP.

1.5 Batasan Masalah

Agar penelitian lebih terarah, maka ditetapkan beberapa batasan sebagai berikut:

1. Data yang digunakan berupa kumpulan kalimat sederhana.
2. Metode yang digunakan adalah TF-IDF dan cosine similarity.
3. Analisis dilakukan pada teks berbahasa Indonesia.
4. Tidak menggunakan model deep learning.

1.6 Sistematika Penulisan

Penulisan penelitian ini disusun dalam beberapa bab sebagai berikut:

BAB I Pendahuluan, berisi latar belakang, rumusan masalah, tujuan, manfaat, batasan masalah, dan sistematika penulisan.

BAB II Tinjauan Pustaka, berisi teori yang mendukung penelitian.

BAB III Metodologi Penelitian, berisi tahapan dan metode yang digunakan.

BAB IV Hasil dan Pembahasan, berisi hasil implementasi dan analisis.

BAB V Penutup, berisi kesimpulan dan saran.

BAB II

TINJAUAN PUSTAKA

2.1 Natural Language Processing

Natural Language Processing (NLP) merupakan cabang dari Artificial Intelligence yang berfokus pada interaksi antara komputer dan bahasa manusia. NLP memungkinkan komputer untuk memahami, mengolah, dan menganalisis teks atau bahasa alami sehingga dapat diubah menjadi informasi yang bermakna.

Dalam penerapannya, NLP digunakan dalam berbagai bidang seperti analisis sentimen, klasifikasi teks, penerjemahan bahasa, hingga sistem pencarian informasi. Salah satu tantangan utama dalam NLP adalah bagaimana mengubah teks yang tidak terstruktur menjadi representasi numerik yang dapat diproses oleh komputer.

2.2 Text Preprocessing

Text preprocessing merupakan tahap awal dalam pengolahan teks yang bertujuan untuk membersihkan dan menyiapkan data sebelum dianalisis lebih lanjut. Tahap ini sangat penting karena kualitas preprocessing akan mempengaruhi hasil akhir dari analisis.

Beberapa tahapan umum dalam preprocessing antara lain:

1. Case folding, yaitu mengubah seluruh teks menjadi huruf kecil
2. Tokenizing, yaitu memecah teks menjadi kata-kata
3. Stopword removal, yaitu menghapus kata-kata yang tidak memiliki makna

penting

4. Punctuation removal, yaitu menghapus tanda baca

Melalui preprocessing, teks yang semula tidak terstruktur dapat menjadi lebih terorganisir dan siap untuk diproses lebih lanjut.

2.3 Feature Extraction

Feature extraction merupakan proses mengubah teks menjadi bentuk numerik agar dapat diproses oleh algoritma komputasi. Tanpa proses ini, komputer tidak dapat memahami teks secara langsung.

Dalam penelitian ini, metode yang digunakan untuk feature extraction adalah TF-IDF. Metode ini mengukur pentingnya suatu kata dalam sebuah dokumen berdasarkan frekuensi kemunculannya.

2.4 Term Frequency – Inverse Document Frequency (TF-IDF)

TF-IDF merupakan metode yang digunakan untuk mengukur seberapa penting suatu kata dalam dokumen dibandingkan dengan keseluruhan dokumen dalam dataset.

TF (Term Frequency) menunjukkan seberapa sering suatu kata muncul dalam dokumen, sedangkan IDF (Inverse Document Frequency) menunjukkan seberapa jarang kata tersebut muncul di seluruh dokumen.

Metode ini memberikan bobot lebih besar pada kata yang sering muncul dalam satu dokumen tetapi jarang muncul di dokumen lain.

2.5 Cosine Similarity

Cosine similarity merupakan metode yang digunakan untuk mengukur tingkat kemiripan antara dua vektor. Dalam konteks NLP, metode ini digunakan untuk mengukur kemiripan antar dokumen berdasarkan representasi vektor TF-IDF.

Nilai cosine similarity berada pada rentang 0 hingga 1, di mana:

- 0 menunjukkan tidak ada kemiripan
- 1 menunjukkan kemiripan yang sangat tinggi

2.6 Representasi Teks

Dalam NLP, representasi teks merupakan langkah penting untuk mengubah data teks menjadi bentuk yang dapat dipahami oleh komputer. Representasi ini biasanya berbentuk vektor numerik yang mencerminkan informasi dari teks tersebut.

TF-IDF merupakan salah satu metode representasi teks yang sederhana namun efektif. Dengan representasi ini, setiap dokumen dapat dibandingkan satu sama lain menggunakan metode similarity.

2.7 Pengukuran Kemiripan Teks

Pengukuran kemiripan teks bertujuan untuk mengetahui seberapa dekat hubungan antara dua teks. Metode ini banyak digunakan dalam sistem pencarian, rekomendasi, dan analisis dokumen.

Dalam penelitian ini, pengukuran kemiripan dilakukan menggunakan cosine similarity terhadap vektor TF-IDF. Hasil dari pengukuran ini berupa nilai numerik yang menunjukkan tingkat kedekatan antara query dan dokumen.

BAB III

METODOLOGI PENELITIAN

3.1 Jenis Penelitian

Penelitian ini merupakan penelitian eksperimental yang bertujuan untuk mengimplementasikan metode Natural Language Processing (NLP) dalam mengukur kemiripan teks. Pendekatan yang digunakan adalah dengan melakukan pengolahan teks, ekstraksi fitur menggunakan TF-IDF, serta pengukuran kemiripan menggunakan cosine similarity.

3.2 Data Penelitian

Data yang digunakan dalam penelitian ini berupa kumpulan kalimat yang merepresentasikan berbagai topik, seperti teknologi, ekonomi, dan olahraga. Data tersebut digunakan sebagai corpus untuk menguji metode TF-IDF dan cosine similarity.

Setiap kalimat dianggap sebagai satu dokumen, sehingga proses analisis dilakukan

dengan membandingkan kemiripan antar dokumen berdasarkan query yang diberikan.

3.3 Tahapan Penelitian

Tahapan penelitian yang dilakukan dalam penelitian ini meliputi beberapa langkah sebagai berikut:

1. Pengumpulan data teks
2. Preprocessing teks
3. Transformasi teks menggunakan TF-IDF
4. Perhitungan cosine similarity
5. Analisis hasil

Tahapan ini dilakukan secara berurutan untuk memperoleh hasil yang optimal.

3.4 Preprocessing Teks

Pada tahap preprocessing, dilakukan beberapa proses untuk membersihkan teks sebelum dianalisis, yaitu:

1. Mengubah seluruh teks menjadi huruf kecil (case folding)
2. Menghapus tanda baca (punctuation removal)
3. Melakukan tokenisasi (tokenizing)
4. Menghapus stopwords (stopword removal)

Tahap ini bertujuan untuk menghasilkan teks yang lebih bersih dan terstruktur sehingga dapat diproses dengan lebih baik.

3.5 Transformasi Teks dengan TF-IDF

Setelah preprocessing, teks diubah menjadi representasi numerik menggunakan metode TF-IDF. Setiap dokumen akan direpresentasikan dalam bentuk vektor berdasarkan bobot kata yang terdapat dalam dokumen tersebut.

Proses ini dilakukan menggunakan library `TfidfVectorizer` dari `scikit-learn`. Hasil dari proses ini adalah matriks TF-IDF yang berisi bobot setiap kata dalam setiap dokumen.

3.6 Perhitungan Cosine Similarity

Setelah diperoleh representasi TF-IDF, langkah selanjutnya adalah menghitung tingkat kemiripan antara query dan dokumen menggunakan metode cosine similarity.

Cosine similarity digunakan untuk mengukur kedekatan antara dua vektor dalam ruang multidimensi. Hasil dari perhitungan ini berupa nilai antara 0 hingga 1 yang menunjukkan tingkat kemiripan antara query dan dokumen.

3.7 Tools dan Lingkungan Pengujian

Penelitian ini dilakukan dengan menggunakan beberapa tools sebagai berikut:

1. Python sebagai bahasa pemrograman
2. NLTK untuk preprocessing teks
3. Scikit-learn untuk TF-IDF dan cosine similarity
4. Google Colab sebagai lingkungan pengembangan

Tools tersebut digunakan karena mendukung proses pengolahan teks secara efisien dan mudah diimplementasikan.

3.8 Alur Penelitian

Secara umum, alur penelitian dalam penelitian ini dapat dijelaskan sebagai berikut:

Input teks → preprocessing → TF-IDF → cosine similarity → hasil similarity

Alur ini menggambarkan proses transformasi teks dari bentuk mentah hingga menghasilkan nilai kemiripan antar dokumen.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Implementasi

Pada penelitian ini dilakukan implementasi metode TF-IDF dan cosine similarity untuk mengukur kemiripan antar teks. Data yang digunakan berupa kumpulan kalimat yang terdiri dari berbagai topik, seperti teknologi, ekonomi, dan olahraga. Proses implementasi dilakukan menggunakan bahasa pemrograman Python dengan bantuan library NLTK dan scikit-learn. Tahapan yang dilakukan meliputi preprocessing teks, transformasi TF-IDF, serta perhitungan cosine similarity.

4.2 Hasil Pengujian

Pengujian dilakukan dengan menggunakan query berupa kata “teknologi”. Hasil perhitungan cosine similarity terhadap seluruh dokumen ditunjukkan sebagai berikut:

Kalimat	3	memiliki	nilai	similarity	sebesar	0.3597
Kalimat	6	memiliki	nilai	similarity	sebesar	0.3156

Kalimat 10 memiliki nilai similarity sebesar 0.4109

Sementara itu, kalimat lainnya memiliki nilai similarity sebesar 0.0000.

4.3 Analisis Hasil

Berdasarkan hasil yang diperoleh, terlihat bahwa kalimat yang mengandung kata “teknologi” memiliki nilai similarity yang lebih tinggi dibandingkan dengan kalimat lainnya. Hal ini menunjukkan bahwa metode TF-IDF berhasil memberikan bobot yang lebih besar pada kata yang relevan terhadap query.

Kalimat dengan nilai similarity tertinggi adalah kalimat ke-10, yaitu “Inovasi dalam bidang teknologi semakin berkembang setiap tahun”, dengan nilai sebesar 0.4109. Hal ini menunjukkan bahwa kalimat tersebut memiliki tingkat kemiripan paling tinggi terhadap query yang diberikan.

Sementara itu, kalimat yang tidak mengandung kata “teknologi” memiliki nilai similarity sebesar 0.0000, yang menunjukkan bahwa tidak terdapat kesamaan antara query dan kalimat tersebut.

4.4 Pembahasan

Hasil penelitian ini menunjukkan bahwa metode TF-IDF dan cosine similarity dapat digunakan secara efektif untuk mengukur kemiripan antar teks. Metode ini mampu mengidentifikasi kata-kata yang relevan dan memberikan bobot yang sesuai berdasarkan frekuensi kemunculan kata.

Namun, metode ini masih memiliki keterbatasan, yaitu hanya mampu mengenali kesamaan berdasarkan kata yang sama secara langsung. Jika terdapat kata yang memiliki makna serupa namun berbeda secara penulisan, maka metode ini tidak dapat mengenali hubungan tersebut.

Dengan demikian, metode TF-IDF dan cosine similarity cocok digunakan untuk analisis teks sederhana, namun untuk analisis yang lebih kompleks dapat dikembangkan menggunakan metode lain yang lebih canggih.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, dapat disimpulkan bahwa metode TF-IDF dan cosine similarity dapat digunakan untuk mengukur kemiripan antar teks secara efektif. Proses preprocessing, transformasi teks, serta perhitungan similarity mampu menghasilkan nilai yang menunjukkan tingkat kedekatan antara query dan dokumen.

Hasil pengujian menunjukkan bahwa kalimat yang mengandung kata yang relevan dengan query memiliki nilai similarity yang lebih tinggi dibandingkan dengan kalimat yang tidak relevan. Hal ini menunjukkan bahwa metode TF-IDF mampu memberikan bobot yang sesuai terhadap kata yang penting dalam dokumen.

Dengan demikian, metode yang digunakan dalam penelitian ini dapat membantu dalam proses analisis teks sederhana, khususnya dalam mengidentifikasi kemiripan antar dokumen berbasis kata.

5.2 Saran

Berdasarkan penelitian yang telah dilakukan, terdapat beberapa saran yang dapat dipertimbangkan untuk pengembangan selanjutnya, antara lain:

1. Menggunakan dataset yang lebih besar dan beragam untuk meningkatkan kualitas analisis.
2. Mengembangkan metode dengan pendekatan yang lebih kompleks, seperti word embedding atau deep learning.
3. Menambahkan proses stemming atau lemmatization untuk meningkatkan kualitas preprocessing.
4. Menggunakan metode similarity lain untuk membandingkan hasil yang diperoleh.

Dengan pengembangan lebih lanjut, diharapkan analisis teks menggunakan NLP dapat memberikan hasil yang lebih akurat dan relevan.